

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

RELATÓRIO TÉCNICO — Data Warehouse Organizacional e DataMarts

Campo	Valor
Instituição	Instituto Federal de Goiás (IFG) — Campus Goiânia
Disciplina	Tópicos Avançados em Inteligência Artificial I
Professor	Sirlon Diniz
Autor	Daniel Flávio
Data de entrega	30/09/2026

1. Objetivo

Construir um **Data Warehouse (DW) Organizacional** integrando duas bases de dados distintas — **Northwind** e **Mercearia** — e, a partir dele, derivar **três DataMarts** de assuntos de negócio distintos, aplicando ferramentas de análise de dados sobre o DW e sobre os DataMarts.

O trabalho observa os conceitos exigidos: **granularidade, integração, historicidade, dimensão tempo e dados externos**, além da **LGPD** nos atributos sensíveis.

2. Descrição das fontes

Fonte	Natureza	Conteúdo verificado
Northwind (sql/northwind.sql)	Dump PostgreSQL com dados	14 tabelas · 830 pedidos · 2.155 itens · 91 clientes · 77 produtos · 29 fornecedores · 9 funcionários · 6 transportadoras · pedidos para 21 países
Mercearia (sql/SQL criação DB Mercearia.sql)	Somente DDL (sem nenhum INSERT)	14 tabelas · 0 registros · endereços brasileiros em 5 níveis (UF → Cidade → Bairro → Logradouro → Endereço)

2.1 Declaração de integridade sobre a Mercearia (importante)

O material de origem da Mercearia **não acompanha dados** — é apenas a definição das tabelas. Para que a integração das duas fontes fosse **demonstrável** (e não apenas desenhada), foi criada uma massa de dados **sintética, declarada e reproduzível** em `sql/seed_mercearia.sql`:

01-nomes de pessoas e empresas **fictícios**;

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

02- CPF/CNPJ **inválidos por construção** (dígitos verificadores não calculados), existindo apenas para


exercitar o mascaramento exigido pela LGPD;

03- UFs com **códigos reais do IBGE** (dado público);

04- 3.171 vendas e 150 compras ao longo de 24 meses (10/2024 a 09/2026), com sazonalidade simulada.

Nenhum dado real de pessoa foi utilizado. O arquivo original da Mercearia permanece intacto no repositório. Esta decisão está registrada no cabeçalho do próprio script.

3. Arquitetura da solução



Stack: PostgreSQL 16 (container postgres:16-alpine) · ETL em **SQL puro** · carga com um único comando · análise em **Python 3.13** (pandas, matplotlib, scikit-learn, psycopg2).

Sobre a ETL: o enunciado permite ferramentas de integração; optou-se por **SQL puro** por

transparência e reprodutibilidade — todo o processo é auditável linha a linha nos scripts etL/.sql,*

sem dependência de licença ou de instalação de ferramenta adicional.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

A **carga completa em um comando** garante a reprodutibilidade exigida em trabalho de engenharia de dados:

```
docker compose up -d
docker compose exec -T db sh /etl/00_carga_inicial.sh
```

Os diagramas (modelo galáxia do DW e os três DataMarts) estão em `diagramas.md`.

4. Decisões de modelagem

Abordagem adotada: **Kimball** — esquema estrela com **barramento de dimensões conformadas**.

4.1 Granularidade (o que cada linha representa)

Fato	Grão	Justificativa
fato_vendas	1 linha por item de pedido/venda	menor nível de detalhe disponível; permite qualquer agregação posterior
fato_compras	1 linha por item de compra	idem, para o processo de suprimentos
fato_entregas	1 linha por pedido /entrega	ver abaixo — o frete é do pedido, não do item

Por que o terceiro fato tem outro grão? No Northwind, `orders.freight` é medido **no pedido**. Se o frete fosse colocado em `fato_vendas` (grão de item), o mesmo valor apareceria **repetido em cada item** do pedido — dupla contagem —, ou teria de ser **rateado**, gerando um número que não existe na origem. A solução dimensional correta é **um fato por grão**, com **dimensões conformadas** compartilhadas. Ou seja: a granularidade não é um detalhe técnico, é uma decisão que **muda o número**.

4.2 Integração das duas fontes

Mecanismo	Como foi aplicado
Chaves naturais por origem	origem (MERCEARIA / NORTHWIND) + chave natural da fonte, com índice único por origem + versão
Dimensões conformadas	produto, cliente, fornecedor, localidade e tempo servem aos três fatos
Padronização de rótulo de país	Brazil (Northwind) e Brasil (Mercearia) viram o mesmo país via tabela de-para <code>ext.pais_nome</code>
Normalização de acento/caixa	Sao Paulo (Northwind) e São Paulo (Mercearia) reconhecidos como a mesma cidade com <code>unaccent()</code>
Chave oficial externa	<code>codigo_ibge</code> no município (IBGE) como chave estável de integração com sistemas oficiais
Homogeneidade de medida	tudo em BRL (ver 4.4)

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

4.3 Historicidade — SCD Tipo 2

Aplicado em ``dim_produto`` (atributo versionado: preço) e ``dim_cliente`` (faixa de renda). A dimensão guarda `versao`, `data_inicio`, `data_fim` e `flag_atual`, com duas garantias no banco: índice único por (origem, chave natural, versão) e **uma única versão vigente** por chave (índice parcial WHERE `flag_atual`).

Declarar "SCD2" no DDL **não prova nada** — por isso o comportamento é **demonstrado** por `etl/90_teste_scd2.sql`, que:

simula mudança na fonte (preço de 3 produtos, renda de 2 clientes);

roda a atualização incremental;

verifica o fechamento da versão antiga e a abertura da nova;

verifica que as vendas antigas permanecem ligadas à versão antiga — o ponto central da historicidade.

Evidência de execução:

Produto	Versão	Preço	Vigente	Data início	Data fim	Vendas ligadas	Total vendido
1 — Arroz Tipo 1 5kg	1	24,90	não	1900-01-01	2026-09-28	324 linhas	R\$ 50.845,80
1 — Arroz Tipo 1 5kg	2	27,39	sim	2026-09-29	—	—	—

O passado **não foi reescrito**. Sem SCD2, as 324 vendas passariam a mostrar o preço novo e a receita histórica seria distorcida.

4.4 Dados externos e conversão de moeda

Dado externo	Fonte	Onde entra	Por quê
Código do município (7 dígitos)	IBGE — Localidades	<code>dim_localidade.codigo_ibge</code>	chave estável de integração com sistemas oficiais
População residente estimada	IBGE — Agregados (6579/9324)	<code>dim_localidade.populacao</code>	permite venda per capita
Cotação USD→BRL	BCB — PTAX/OLINDA	<code>fato_vendas.taxa_cambio</code>	o Northwind está em USD e a Mercearia em BRL
Feriados e pontos facultativos	calculados (Páscoa por Meeus/Jones/Butcher)	<code>dim_tempo</code>	sazonalidade depende de calendário

Extração documentada e reproduzível em `etl/05_extrair_dados_externos.ps1`: **39 municípios** e **750 cotações** PTAX (02/01/1996 a 31/12/1998), com data de acesso registrada em `dados_externos/README.md`.

Regra do câmbio (decisão registrada):

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

converte-se USD → BRL pela **cotação de compra** do dia da venda;
sem boletim no dia (fim de semana/feriado), usa-se a **última cotação disponível** (*carry forward*),

materializada em `ext.cotacao_dolar_dia` (1.095 dias);

a taxa efetivamente aplicada é **gravada na linha do fato** (`taxa_cambio`), junto com `moeda_origem`.

Taxas efetivamente aplicadas: de **1,0040 a 1,1445** BRL por USD. Motivo de fundo: somar USD com BRL produz um número sem significado — violação do princípio de **homogeneidade das medidas**.

4.5 Dimensão tempo

`dim_tempo` no grão de **dia**, cobrindo **01/01/1996 a 31/12/2026 = 11.323 dias**.

O período é a **união** dos períodos dos fatos (Northwind 1996–1998 + Mercearia 2024–2026). Gerar apenas o período recente deixaria as 2.155 linhas de venda do Northwind **órfãs** (sem linha na dimensão).

Conteúdo: ano, semestre, trimestre, mês, nome do mês, dia, dia da semana, indicador de fim de semana, **281 feriados legais** e **62 pontos facultativos**. `dim_tempo` é usada em **papel duplo** em todos os fatos (ex.: data da venda e data do faturamento).

***Rigor conceitual: Carnaval e Corpus Christi** foram marcados como ponto facultativo, e*

***não** como feriado — não são feriados legais. Já o **20/11 (Consciência Negra)** só é marcado como*

*feriado **a partir de 2024**, respeitando a Lei 14.759/2023. Essa distinção produziu um achado de*

negócio (item 7.4).

4.6 Modelo final do DW

Tipo	Objetos
Dimensões	<code>dim_tempo</code> , <code>dim_localidade</code> , <code>dim_produto</code> , <code>dim_cliente</code> , <code>dim_vendedor</code> , <code>dim_fornecedor</code> , <code>dim_transportadora</code>
Fatos	<code>fato_vendas</code> (item), <code>fato_compras</code> (item), <code>fato_entregas</code> (pedido)

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

Ponto de atenção modelado e documentado: `dim_localidade` tem **profundidade variável** — no Brasil chega ao **bairro** (121 membros, com CEP representativo e código IBGE) e no exterior fica no nível **cidade/região** (66 membros, 21 países). O Northwind envia para 21 países, e não apenas para os EUA — fato apurado nos dados, não presumido. Agregações por cidade/país funcionam porque `nm_cidade` e `pais` são consistentes entre os dois níveis.

5. DataMarts

Cada DataMart é um **esquema estrela próprio**, materializado como **tabelas físicas** no PostgreSQL e carregado **a partir do DW** (o entregável pede a DDL dos DataMarts). As dimensões mantêm a **mesma chave surrogate** do DW, garantindo a conformidade — verificado por teste automatizado.

#	DataMart	Assunto	Fato (grão)	Dimensões	Linhas
1	dm_vendas	desempenho comercial	fato_vendas (item)	tempo (papel duplo), produto, cliente, localidade, vendedor	11.651
2	dm_suprimentos	abastecimento e custo	fato_compras (item)	tempo (papel duplo), produto, fornecedor	302
3	dm_logistica	distribuição e frete	fato_entregas (pedido)	tempo (papel duplo), cliente, localidade, transportadora	830

5.1 Justificativa de uso de cada DataMart

1 — Vendas. Maior alcance: apoia decisões de **preço, mix de produtos, desconto, campanha e alocação de vendedor**. Responde: o que vende, para quem, onde, por quem e quando; qual o custo do desconto; como a venda reage a fim de semana e feriado.

2 — Suprimentos. Apoia a decisão de **compra**: de quem comprar, a que custo, com que prazo. O Northwind não possui compras, então este DataMart é da operação da Merceria — **mas compartilha a mesma `dim\_produto`** do DataMart de Vendas, o que permite o cruzamento mais valioso do trabalho: **custo de aquisição × preço de venda → margem por produto**.

3 — Logística. Existe por razão técnica demonstrada (item 4.1): o frete é do **pedido**. Apoia a operação na escolha e cobrança de transportadora: prazo médio, frete médio, destinos problemáticos e efeito de feriado no prazo.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

5.2 Recorte aplicado nos DataMarts

05- **Em linhas:** cada DataMart carrega apenas os membros de dimensão **usados pelos seus fatos** (recorte

que também reduz volume: dm_logistica usa 4 dimensões, não 7).

06- **Em colunas (LGPD):** em dm_logistica.dim_cliente foram **omitidos** CPF mascarado, faixa de renda e

data de nascimento — o assunto é entrega, não perfil de consumo (princípio de **minimização**).

07- **SCD2 preservado:** entram **todas as versões** referenciadas pelos fatos. Carregar apenas a versão

vigente deixaria as vendas antigas **órfãs dentro do DataMart**.

6. Processo de ETL

6.1 Etapas (todas em etl/, executadas em sequência por 00_carga_inicial.sh)

Etapas	Script	O que faz
1	sql/northwind.sql + SQL criação DB Mercearia.sql	Extract: carrega as duas fontes no schema public
2	sql/seed_mercearia.sql	seed sintético declarado da Mercearia (idempotente)
3	sql/01_dw_organizacional.sql	DDL do DW (idempotente: recria o schema dw)
4	sql/03_dados_externos.sql	dados externos: IBGE + PTAX + calendário de câmbio + de-para de país
5	sql/02_dim_tempo.sql	carga da dimensão tempo + feriados (Páscoa calculada)
6	etl/10_carga_dimensoes.sql	Transform + Load das 7 dimensões (inclui mascaramento LGPD)
7	etl/20_carga_fatos.sql	carga dos 3 fatos (conversão de moeda e papel duplo de tempo)
8	etl/99_validacao.sql	testes de integridade do DW
9	sql/04_datamarts.sql	DDL dos 3 DataMarts
10	etl/30_carga_datamarts.sql	carga dos DataMarts a partir do DW (com recorte)
11	etl/40_validacao_datamarts.sql	testes de integridade e de conformidade entre DataMarts

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

6.2 Principais transformações

08- **Padronização de moeda:** USD → BRL pela PTAX do dia, com a taxa gravada no fato (auditoria).

09- **Padronização de rótulo:** país (de-para) e cidade (unaccent, case-insensitive).

10- **Generalização (LGPD):** CPF/CNPJ → '***.***.***-XX'; renda exata → **faixa** de renda; telefones

não carregados.

11- **Tratamento de nulos:** 21 pedidos sem expedição (prazo/data nulos), 507 sem região, campos de

faturamento/entrada opcionais — todos preservados como NULL, sem valor inventado.

12- **Derivação:** valor bruto, valor de desconto, valor líquido e prazo de entrega.

Regra de arredondamento que garante a identidade da linha: $vlr_bruto = round(quantidade \times vlr_unitario, 2)$
 $vlr_desconto = round(vlr_bruto \times pct_desconto, 2)$
 $vlr_liquido = vlr_bruto - vlr_desconto$.

6.3 Testes de integridade — resultados

DW (etl/99_validacao.sql):

Teste	Resultado
Contagens origem × DW (13 comparações)	todas iguais (ex.: fato_vendas 9.496 Mercearia + 2.155 Northwind)
Identidade contábil (vlr_bruto, vlr_liquido) em 11.651 linhas	0 erros
Valores negativos	0
Vendas sem localidade	0
Registros órfãos (5 FKs testadas)	0
SCD2: uma única versão vigente por chave (107 chaves)	100%
Cobertura dos dados externos na dimensão	120 membros com código IBGE e população

DataMarts (etl/40_validacao_datamarts.sql):

Teste	Resultado
Fatos do DataMart × DW (3 comparações)	iguais
Órfãos nos DataMarts	0
Conformidade entre DataMarts (mesmo membro → mesmos atributos)	0 divergências (produto, localidade, cliente, tempo)
Membros carregados e não usados	0 (o recorte funcionou)
LGPD: colunas sensíveis em dm_logistica.dim_cliente	0 (teste via catálogo information_schema)
Amostra analítica sobre o DataMart	top 5 produtos retornado corretamente

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

6.4 Defeitos encontrados durante a execução (e corrigidos)

Registro honesto do processo — todos foram detectados **por teste**, não por inspeção visual:

#	Defeito	Como foi detectado	Correção
1	Telefones: ordem de colunas invertida no INSERT (ID duplicado)	erro de chave primária na carga	reordenação da lista de colunas
2	203 linhas do Northwind sem localidade	teste de integridade do DW	o filtro de país excluía os destinos brasileiros; a junção passou a usar o país padronizado e o nível de cidade
3	Cidade Sao Paulo ≠ São Paulo (duas cidades na mesma dimensão)	análise de dados	normalização com unaccent()
4	UF SP duplicada (uma sem nome de estado)	análise de dados	preenchimento de nm_estado a partir da tabela Uf
5	curl no Windows interpretando [] como curinga	falha de rede na extração	uso de -g e codificação %5B/%5D

Lição de qualidade de dados: os defeitos 3 e 4 **passaram por todos os testes de contagem** e só apareceram **no uso analítico**. Teste de contagem não substitui **teste de uso**.

7. Análise de dados

Ferramenta: Python 3.13 (pandas, matplotlib, scikit-learn, psycpg2), conectado diretamente ao banco, aplicado **ao DW e aos DataMarts**. Script: `analise/analise_dw_datamarts.py`. Detalhamento completo em `analises.md`; saídas em `analise/figuras/` (8 gráficos) e `analise/resultados/` (11 tabelas).

7.1 Panorama

Indicador	Valor
Linhas de venda (DW e DataMart)	11.651
Faturamento total (BRL)	1.991.124,46
Prazo médio de entrega	8,5 dias
Frete médio por pedido	R\$ 85,20

Visão temporal (DW). O gráfico abaixo mostra as duas fontes no tempo — Northwind 1996–1998 e Mercearia 2024–2026 — e evidencia que **dezembro é pico nas duas bases**.




Figura 1 — Evolução mensal do faturamento (BRL) por origem.




Figura 2 — Top 10 produtos por faturamento (BRL).

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira		
	Tópicos Avançados de IA 1	Especialização em IA Aplicada	
	Professor: Sirlon Diniz	Data: 29/09/2026	




Figura 3 — Faturamento por UF (Brasil).

7.2 Sazonalidade (DW, usando dim_tempo)

Fim de semana vende **~1,5× mais** que dia útil (sábado R\$ 1.143,19/dia × segunda R\$ 749,24/dia). **Feriado legal vende 21% MENOS** que um dia comum (R\$ 670,76 contra R\$ 846,29), enquanto **ponto facultativo vende mais** (R\$ 947,02). O comportamento diferente é o que **justifica** a existência da flag separada eh_ponto_facultativo na dimensão tempo.




Figura 4 — Venda média por dia da semana e por tipo de dia (feriado × dia comum).

7.3 Logística e conformidade (DataMart 3)

Transportadora	Pedidos	Prazo médio	Frete médio
Federal Shipping	255	7,5 dias	R\$ 87,00
Speedy Express	249	8,6 dias	R\$ 70,79
United Package	326	9,2 dias	R\$ 94,80

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

United Package concentra o maior volume, tem o **pior prazo** e o **maior frete** — prioridade de renegociação. Não há trade-off "rápido × barato" nos dados.




Figura 5 — Prazo médio de entrega por transportadora (dias).

7.4 Análise cruzada de DataMarts (margem)

O cruzamento `dm_suprimentos (custo)` × `dm_vendas (preço)` só é possível porque as dimensões são **conformadas**. **Limitação declarada:** a margem apurada ficou uniformemente em 35% por um **artefato do seed sintético** (custo gerado como 65% do preço) — o **método** está correto, o **número** não é interpretável. Com dados reais, a margem variaria por produto.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026




Figura 6 — Margem unitária média por produto (BRL) — cruzamento entre os DataMarts de Suprimentos e Vendas.

7.5 IA aplicada

Segmentação de clientes (K-Means sobre RFM) — 60 clientes em 3 grupos. Destaque: o segmento

intermediário (13 clientes) tem valor próximo ao topo, mas **46 dias de recência** — alvo natural de campanha de reativação. *Limitação*: no seed sintético todos compram com frequência parecida, então o agrupamento separou sobretudo por **valor**.

Projeção de vendas (regressão linear) — $R^2 = 0,866$, tendência praticamente estável

(-R\$ 31,76/mês) e **efeito de dezembro de +R\$ 21.686,08**; projeção de dezembro: R\$ 44.994,89. O R^2 alto decorre do **efeito sazonal**, não de crescimento.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026




Figura 7 — Segmentação de clientes por K-Means ($k=3$) sobre recência × valor.




Figura 8 — Faturamento mensal e projeção por regressão linear ($R^2 = 0,866$).

7.6 Achados de negócio

Fim de semana vende $\sim 1,5\times$ mais; **feriado legal vende 21% menos**.

Dezembro é pico nas **duas** bases — sazonalidade consistente entre fontes de épocas diferentes.

A Mercearia fatura por **volume**; o Northwind, por **valor unitário**.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

United Package: maior volume, pior prazo, maior frete.

13 clientes com 46 dias de recência: melhor oportunidade de reativação.

SP lidera o faturamento, mas **GO** é o 2º em número de pedidos (efeito da base local).

8. LGPD

Aplicada de forma **preventiva** — ainda assim relevante, porque o DW modelado lidaria com dados pessoais se alimentado por uma base real (Lei 13.709/2018). Medidas implementadas:

Medida	Onde
Minimização — apenas os atributos necessários entram no DW	telefones (Telefones) não são carregados; nenhum uso analítico existe para eles
Mascaramento — CPF/CNPJ reduzido a '***.***.***-XX'	dim_cliente.cpf_cnpj_masked
Generalização — renda exata → faixa de renda	dim_cliente.faixa_renda
Minimização por assunto — CPF, renda e data de nascimento omitidos	dm_logistica.dim_cliente (teste D5 verifica via catálogo)
Dados sintéticos declarados — nenhum dado real de pessoa	sql/seed_mercearia.sql
Dado público — o <i>sample</i> Northwind é fictício	sql/northwind.sql

9. Limitações e trabalhos futuros

Massa sintética na Mercearia — necessária porque a fonte não acompanha dados. Consequência:

margem uniforme e clientes homogêneos em frequência (itens 7.4 e 7.5). Com dados reais, os achados seriam mais ricos.

Salto temporal entre as fontes — Northwind 1996–1998 e Mercearia 2024–2026: os dados são integrados por dimensões conformadas, mas **não** devem ser lidos como uma série contínua de uma mesma economia (a conversão cambial garante homogeneidade de moeda, não comparabilidade de mercado).

Dimensão localidade com profundidade variável (bairro no Brasil, cidade no exterior) — alternativa

futura: desmembrar em dim_cidade + dim_bairro (flocos de neve).

Projeção linear é didática (24 pontos, 2 variáveis); a evolução natural seria SARIMA/Prophet usando

os atributos de dim_tempo (feriados, dia da semana).

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

Carga completa (full load) em vez de incremental — adequado ao volume acadêmico; em produção,

haveria carga incremental com controle de watermark.

10. Conclusão

O trabalho entregou um DW Organizacional que **integra de fato** duas fontes de estruturas e semânticas diferentes: 4 dimensões recebem registros das duas bases, os rótulos conflitantes foram padronizados (país e acento de cidade) e as medidas foram tornadas homogêneas pela conversão cambial auditável.

Os três requisitos foram atendidos: (1) DW integrando Northwind e Mercearia; (2) **três DataMarts** modelados com assunto, fato, grão, dimensões e justificativa, materializados com DDL própria e validados por testes de conformidade; (3) **análise de dados aplicada ao DW e aos DataMarts**, incluindo dois modelos de aprendizado de máquina.

Os conceitos exigidos não ficaram no texto: **granularidade** gerou um fato adicional (frete), **integração** exigiu tabela de-para e normalização de texto, **historicidade** foi demonstrada com vendas antigas preservadas na versão antiga do preço, a **dimensão tempo** cobre a união dos períodos, os **dados externos** enriquecem localidade e câmbio, e a **LGPD** orientou quatro decisões de minimização e ofuscação. Por fim, a execução real revelou cinco defeitos que os testes capturaram — evidência de que o processo foi **verificado**, e não apenas escrito.

11. Referências

- 13-KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3. ed. Wiley, 2013.
- 14- INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). *API de Localidades e Agregados* (6579/9324 — população residente estimada). Acesso em: 29 set. 2026.
- 15- BANCO CENTRAL DO BRASIL. *PTAX — Cotações e boletins* (OLINDA). Acesso em: 29 set. 2026.
- 16- BRASIL. *Lei nº 13.709, de 14 de agosto de 2018* (Lei Geral de Proteção de Dados Pessoais).
- 17- BRASIL. *Lei nº 14.759, de 21 de dezembro de 2023* (feriado nacional de 20 de novembro).
- 18- NORTHWIND. *Sample database* (distribuído publicamente para fins didáticos).

Anexos

Anexo	Arquivo
DDL do DW	sql/01_dw_organizacional.sql
DDL da dimensão tempo e carga	sql/02_dim_tempo.sql

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 29/09/2026

Anexo	Arquivo
DDL dos dados externos	sql/03_dados_externos.sql
DDL dos DataMarts	sql/04_datamarts.sql
Carga completa (um comando)	etl/00_carga_inicial.sh
Extração de dados externos	etl/05_extrair_dados_externos.ps1
ETL das dimensões e dos fatos	etl/10_carga_dimensoes.sql, etl/20_carga_fatos.sql
Teste de historicidade (SCD2)	etl/90_teste_scd2.sql
Testes de integridade	etl/99_validacao.sql, etl/40_validacao_datamarts.sql
Diagramas (DW e DataMarts)	docs/diagramas.md
Modelagem e justificativa dos DataMarts	docs/datamarts.md
Análise de dados	docs/analises.md + analise/analise_dw_datamarts.py
Dados externos (CSV + fontes)	dados_externos/