

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

RELATÓRIO TÉCNICO — DATA WAREHOUSE ORGANIZACIONAL E DATAMARTS

Campo	Valor
Instituição	Instituto Federal de Goiás (IFG) — Campus Goiânia
Disciplina	Tópicos Avançados em Inteligência Artificial I
Professor	Sirlon Diniz
Autor	Daniel Flávio
Data de entrega	30/09/2026
Repositório	https://github.com/danflavio/ifg-atividade-dw-datamart

1. Objetivo

Construir um **Data Warehouse (DW) Organizacional** que integra duas bases diferentes — **Northwind** e **Mercearia** — e, a partir dele, criar **três DataMarts** de assuntos distintos, aplicando ferramentas de análise de dados sobre o DW e sobre os DataMarts.

O trabalho atende aos conceitos pedidos: **granularidade**, **integração**, **historicidade**, **dimensão tempo**, **dados externos** e **LGPD**.

2. Fontes de dados

Fonte	O que contém
Northwind	Dump PostgreSQL com dados : 830 pedidos, 2.155 itens, 91 clientes, 77 produtos, 29 fornecedores, 9 funcionários, 6 transportadoras e entregas em 21 países
Mercearia	Somente DDL , sem nenhum registro: 14 tabelas, com endereços brasileiros em 5 níveis (UF → Cidade → Bairro → Logradouro → Endereço)

Declaração sobre a Mercearia

O material de origem da Mercearia **não acompanha dados**. Para que a integração das duas fontes fosse demonstrável, foi criada uma massa **sintética e declarada** (sql/seed_mercearia.sql): nomes e empresas fictícios, **CPF/CNPJ inválidos por construção** (só para exercitar o mascaramento) e 3.171 vendas ao longo de 24 meses. **Nenhum dado real de pessoa foi usado**, e o arquivo original permanece intacto.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

3. Arquitetura da solução

```
Northwind ---\
    >--- public (staging) ---> dw (DW: 7 dimensões + 3 fatos)
Mercearia ---/
IBGE -----\
BCB/PTAX ---/--> ext (dados externos)    +---> dm_vendas      (assunto: comercial)
                                           +---> dm_suprimentos (assunto: compras)
                                           +---> dm_logistica  (assunto: entregas)
```

01-**SGBD**: PostgreSQL 16 em Docker. Tudo sobe e carrega com **um comando**:

`docker compose exec -T db sh /etl/00_carga_inicial.sh`

02-**ETL**: em **SQL puro** (o enunciado permite ferramenta; optou-se por SQL por ser auditável e reproduzível sem instalar nada além do banco).

4. Decisões de modelagem

4.1 Granularidade: o que cada linha representa

Fato	Grão	Por quê
fato_vendas	1 linha por item de pedido	menor detalhe disponível; permite somar depois
fato_compras	1 linha por item de compra	mesma razão, para o processo de compras
fato_entregas	1 linha por pedido	o frete é medido no pedido, não no item

Por que o terceiro fato tem outro grão? No Northwind, o frete (`orders.freight`) é um valor **do pedido**. Se fosse colocado no fato de item, o mesmo frete apareceria **repetido em cada item** do pedido (dupla contagem) ou teria que ser rateado — um número que não existe na origem. A solução correta é **um fato por grão**, com **dimensões conformadas** compartilhadas. Ou seja: a granularidade não é detalhe técnico, ela **muda o resultado do número**.

4.2 Integração das duas fontes

Mecanismo	Aplicação
Chave natural por origem	coluna origem (MERCEARIA / NORTHWIND) + chave da fonte
Dimensões conformadas	produto, cliente, fornecedor, localidade e tempo servem aos três fatos
Padronização de país	Brazil (Northwind) e Brasil (Mercearia) viram o mesmo país
Normalização de texto	Sao Paulo e São Paulo reconhecidos como a mesma cidade
Chave oficial externa	<code>codigo_ibge</code> no município, para casar com sistemas oficiais

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

4.3 Historicidade — SCD Tipo 2

Aplicado em ``dim_produto`` (preço) e ``dim_cliente`` (faixa de renda). A dimensão guarda versao, data_inicio, data_fim e flag_atual.

Não basta declarar no DDL — foi testado. O teste (etl/90_teste_scd2.sql) altera o preço do arroz na origem e recarrega a dimensão:

Versão	Preço	Vigente	Data fim	Vendas ligadas
1	24,90	não	28/09/2026	324 linhas (R\$ 50.845,80)
2	27,39	sim	—	—

As **vendas antigas continuaram presas à versão antiga**, com o preço da época. Sem SCD2, o passado seria reescrito e a receita histórica ficaria distorcida.

4.4 Dimensão tempo

dim_tempo no grão de **dia**, de **01/01/1996 a 31/12/2026 = 11.323 dias**, com **281 feriados** e **62 pontos facultativos**. O período é a **união** dos períodos das duas fontes: se fosse gerado só o período recente, as 2.155 vendas do Northwind ficariam **órfãs**. A dimensão é usada em **papel duplo** (ex.: data da venda e data do faturamento).

Rigor conceitual: Carnaval e Corpus Christi foram marcados como **ponto facultativo**, e não como feriado, porque **não são feriados legais**. O 20/11 (Consciência Negra) só é feriado **a partir de 2024**, conforme a Lei 14.759/2023. Essa distinção gerou um achado de negócio (item 7).

4.5 Dados externos e conversão de moeda

Dado externo	Fonte	Onde entra
Código do município e população	IBGE	dim_localidade
Cotação USD→BRL do dia	BCB / PTAX	fato_vendas.taxa_cambio
Feriados (calculados pela Páscoa)	calendário	dim_tempo

Foram extraídos **39 municípios** e **750 cotações** PTAX (1996–1998), com fonte e data de acesso registradas em dados_externos/README.md.

Por que converter? O Northwind está em **dólar** e a Mercearia em **real**. Somar as duas moedas produziria um número sem sentido. A regra adotada: converter pela **PTAX de compra do dia da venda** e **gravar a taxa na própria linha** do fato, para permitir auditoria. Taxas aplicadas: de **1,0040 a 1,1445** BRL por USD.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

5. DataMarts

Cada DataMart é um **esquema estrela próprio**, materializado como tabelas físicas e carregado a partir do DW. As dimensões mantêm a **mesma chave** do DW, e isso é verificado por teste.

#	DataMart	Assunto	Fato (grão)	Dimensões	Linhas
1	dm_vendas	desempenho comercial	fato_vendas (item)	tempo (papel duplo), produto, cliente, localidade, vendedor	11.651
2	dm_suprimentos	compras e abastecimento	fato_compras (item)	tempo (papel duplo), produto, fornecedor	302
3	dm_logistica	entregas e frete	fato_entregas (pedido)	tempo (papel duplo), cliente, localidade, transportadora	830

1 — Vendas. Apoia decisões de preço, mix de produtos, desconto e alocação de vendedor. Dimensões: tempo (papel duplo), produto, cliente, localidade e vendedor.

2 — Suprimentos. Apoia a decisão de compra: de quem comprar, a que custo e com que prazo. O Northwind não tem compras, então este DataMart é da Mercearia — **mas compartilha a mesma `dim\_produto`** do DataMart de Vendas, o que permite cruzar **custo de compra × preço de venda**.

3 — Logística. Existe pela razão técnica do item 4.1: o frete é do pedido. Apoia a escolha de transportadora (prazo e frete) e mostra o efeito de feriados no prazo.

Recorte: cada DataMart carrega apenas as dimensões e os membros que os seus fatos usam. No DataMart de Logística, CPF, faixa de renda e data de nascimento foram **omitidos** (minimização de dados). Todas as versões históricas usadas pelos fatos são mantidas, senão as vendas antigas ficariam órfãs.

6. Processo de ETL e testes

Etapa	O que faz
Extract	carrega Northwind e Mercearia no schema public e cria a massa sintética declarada
Dados externos	carga do IBGE, da PTAX, do calendário de câmbio e dos feriados
Transform + Load	dimensão tempo, as 7 dimensões (com mascaramento LGPD) e os 3 fatos (com conversão de moeda)

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

Etapa	O que faz
DataMarts	cria e carrega os 3 DataMarts e roda os testes de integridade

Transformações principais: conversão USD→BRL com a taxa gravada; padronização de país e de nome de cidade; mascaramento de CPF/CNPJ; generalização de renda em faixas; telefones **não** carregados; tratamento de nulos (21 pedidos sem expedição, por exemplo) sem inventar valor.

Resultados dos testes:


Teste	Resultado
Contagens origem × DW (13 comparações)	todas iguais
Identidade contábil das medidas (11.651 linhas)	0 erros
Registros órfãos	0
Versão vigente única por chave (SCD2)	100%
Conformidade entre DataMarts (mesmo membro = mesmos valores)	0 divergências
LGPD: colunas sensíveis no DataMart de Logística	0

Defeitos encontrados e corrigidos no processo: 7 no total. Dois deles merecem registro, porque **passaram por todos os testes de contagem** e só apareceram quando o dado foi **usado** na análise: a mesma cidade entrando duas vezes (Sao Paulo e São Paulo) e a UF SP aparecendo com dois rótulos diferentes. A lição: **teste de contagem não substitui teste de uso**.

7. Análise de dados

Ferramenta: Python 3.13 (pandas, matplotlib, scikit-learn), conectado direto ao banco e aplicado **ao DW e aos DataMarts**. Script: analise/analise_dw_datamarts.py.

Faturamento total: **R\$ 1.991.124,46** · prazo médio de entrega: **8,5 dias** · frete médio: **R\$ 85,20**.



 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

Figura 1 — Evolução mensal do faturamento (BRL) por origem (Northwind 1996–1998 e Mercearia 2024–2026).

Resultados principais:

Sazonalidade: fim de semana vende **~1,5× mais** que dia útil. E ****feriado legal vende 21% MENOS** que um dia comum (R\$ 670,76 contra R\$ 846,29), enquanto **Carnaval e Corpus Christi (ponto facultativo) vendem mais (R\$ 947,02)** — o que justifica** a flag separada na dimensão tempo.

Dezembro é pico nas duas bases, mesmo sendo fontes de épocas diferentes.

Mercearia fatura por volume; Northwind por valor unitário — o topo do ranking é dominado por produtos caros do Northwind, enquanto a fralda lidera na Mercearia.

Logística: a United Package concentra o maior volume (326 pedidos), tem o **pior prazo** (9,2 dias) e o **maior frete** (R\$ 94,80) — prioridade de renegociação.




Figura 2 — Prazo médio de entrega por transportadora (dias).

IA — segmentação de clientes (K-Means sobre RFM): 60 clientes em 3 grupos. O grupo intermediário (13 clientes) tem valor próximo ao topo, mas **46 dias sem comprar** — melhor oportunidade de reativação.




Figura 3 — Segmentação de clientes (K-Means, k=3) sobre recência × valor.

IA — projeção de vendas (regressão linear): $R^2 = 0,866$, com **efeito de dezembro de +R\$ 21.686,08 (projeção do próximo dezembro: R\$ 44.994,89). O bom ajuste vem da sazonalidade, não de crescimento.**




Figura 4 — Faturamento mensal e projeção por regressão linear.

Limitações declaradas: a margem por produto saiu uniforme em 35% por ser **artefato dos dados sintéticos** (o custo foi gerado como 65% do preço) — o método está correto, o número não é

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

interpretável. E o seed sintético faz os clientes comprarem com frequência parecida, então a segmentação separou sobretudo por valor. Com dados reais, ambos os resultados seriam mais ricos.

8. LGPD

Aplicada de forma preventiva, embora os dados usados sejam públicos ou sintéticos:

Medida	Onde
Minimização — telefones não entram no DW	tabela Telefones
Mascaramento — CPF/CNPJ vira ***.***.***-XX	dim_cliente.cpf_cnpj_masked
Generalização — renda exata vira faixa	dim_cliente.faixa_renda
Minimização por assunto — sem CPF, renda e nascimento no DataMart de entregas	dm_logistica.dim_cliente
Dados sintéticos declarados — nenhum dado real de pessoa	sql/seed_mercearia.sql

9. Conclusão

O trabalho entregou um DW que **integra de fato** duas fontes de estruturas e semânticas diferentes: quatro dimensões recebem registros das duas bases, os rótulos conflitantes foram padronizados e as medidas ficaram homogêneas com conversão cambial auditável.

Os três itens da atividade foram atendidos: (1) o DW integrando Northwind e Mercearia; (2) **três DataMarts** modelados com assunto, grão, dimensões e justificativa, com DDL própria; (3) **análise de dados aplicada ao DW e aos DataMarts**, incluindo dois modelos de aprendizado de máquina.

Os conceitos pedidos não ficaram no texto: **granularidade** gerou um fato adicional (frete), **integração** exigiu padronização de país e de texto, **historicidade** foi demonstrada com as vendas antigas preservadas no preço da época, a **dimensão tempo** cobre a união dos períodos, os **dados externos** enriquecem localidade e câmbio, e a **LGPD** orientou quatro decisões de minimização.

Limitações: a Mercearia não acompanha dados, então sua massa é sintética e declarada; as duas fontes são de épocas distantes, portanto não devem ser lidas como uma série contínua de uma mesma economia; e o modelo de projeção é didático (24 pontos, 2 variáveis).

10. Referências e anexos

Referências: KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit*. 3. ed. Wiley, 2013. · IBGE — API de Localidades e Agregados (acesso em 29/09/2026) · BCB — PTAX/OLINDA (acesso em 29/09/2026) · BRASIL, Lei 13.709/2018 (LGPD) · BRASIL, Lei 14.759/2023.

 INSTITUTO FEDERAL GOIÁS Campus Anápolis	Estudante: Daniel Flávio de Oliveira	
	Tópicos Avançados de IA 1	Especialização em IA Aplicada
	Professor: Sirlon Diniz	Data: 30/09/2026

Anexo	Arquivo
DDL do DW e dos DataMarts	sql/01_dw_organizacional.sql, sql/04_datamarts.sql
Dimensão tempo e dados externos	sql/02_dim_tempo.sql, sql/03_dados_externos.sql
Carga completa (um comando) e ETL	etl/00_carga_inicial.sh, etl/10_carga_dimensoes.sql, etl/20_carga_fatos.sql, etl/30_carga_datamarts.sql
Testes (integridade e historicidade)	etl/99_validacao.sql, etl/40_validacao_datamarts.sql, etl/90_teste_scd2.sql
Análise (script, gráficos e tabelas)	analise/
Diagramas do DW e dos DataMarts	docs/diagramas.md

Repositório completo (código, ETL, testes e análises): <https://github.com/danflavio/ifg-atividade-dw-datamart>